T.C. KOCAELİ ÜNİVERSİTESİ FEN BİLİMLERİ ENSTİTÜSÜ BİLİŞİM SİSTEMLERİ MÜHENDİSLİĞİ

BÜYÜK DİL MODELLERİ FİNAL PROJESİ RAPORU

THE MET KOLEKSİYONU ÜZERİNDE UÇTAN UCA RAG MİMARİSİ VE FINE-TUNING SİSTEMİ TASARIMI

Sude ÖZMEN – 255172006

Haziran 2026

İçindekiler

1. Problem Tanımı 3

2. Veri Hazırlığı 3

3. Baseline Sistem (Vize) 5

4. Embedding × Chunking Kombinasyon Analizi 5

5. Gelişmiş RAG Sistemi 5

6. Retriever-Only Sonuçları 7

7. LLM-Only Sonuçları 7

8. RAG Sonuçları 8

9. Fine-Tuning Veri Seti ve Hazırlık Süreci 8

10. Fine-Tuning Yöntemi ve Eğitim Süreci 9

11. Fine-Tuned Model Sonuçları (No RAG) 10

12. RAG + Fine-Tuned Model Sonuçları 10

13. Tüm Sistemlerin Karşılaştırılması 10

14. Stress Test Analizi 14

15. OOD (Out-of-Domain) Test Analizi 14

16. Hallucination Örnekleri ve Hata Analizi 14

17. Tartışma 14

18. Sonuç 15

19. Proje Kodları ve Araştırma Tekrarlanabilirliği (Reproducibility) 15

EKLER 16

Ek-A: Detaylı Model Yanıtları ve Metrik Dağılımları 16

Örnek 1 (Soru Tipi: Normal) 16

Örnek 2 (Soru Tipi: OOD / Bilgi Dışı) 17

Örnek 3 (Soru Tipi: Multi-hop) 17

Örnek 4 (Soru Tipi: Paraphrase) 18

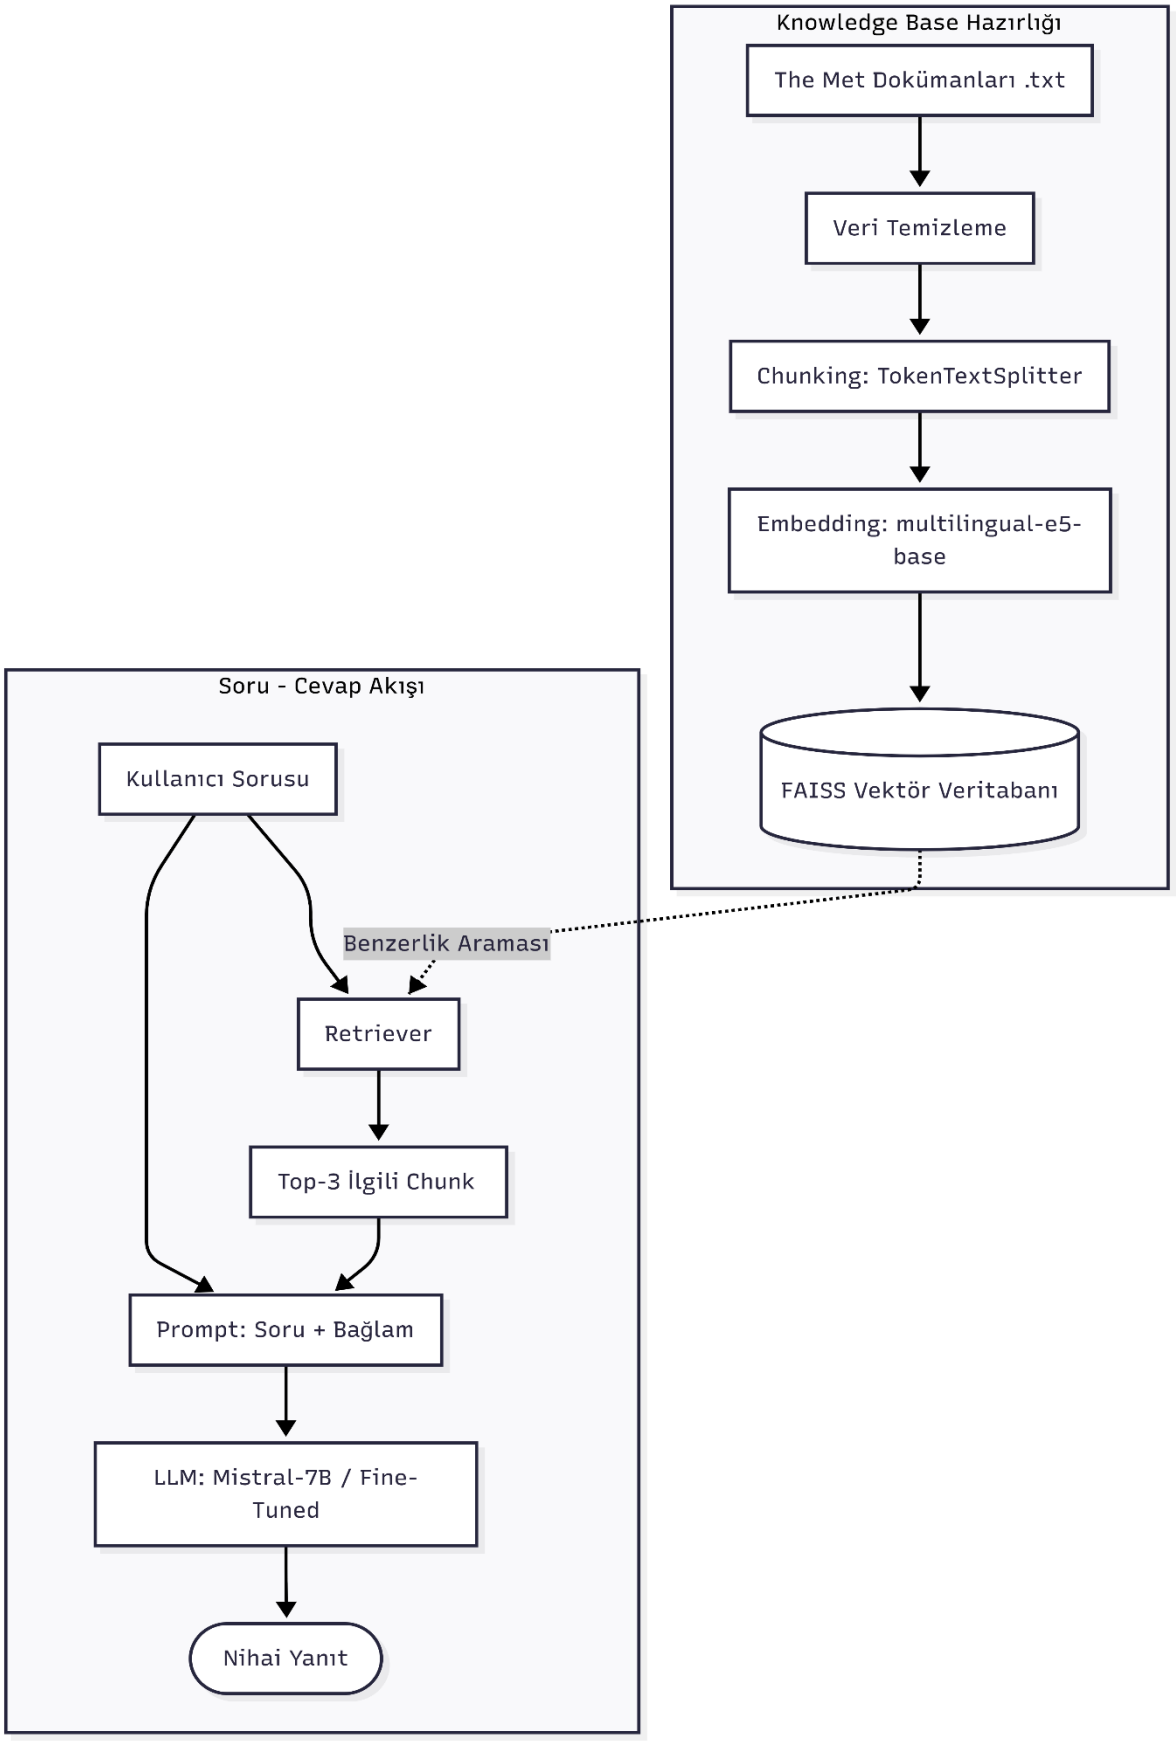
Örnek 5 (Soru Tipi: Stress) 19

1. Problem Tanımı

Büyük müze koleksiyonları gibi alan-özgü (domain-specific) bilgi tabanlarında, kullanıcıların doğal dil sorularına doğru ve güvenilir yanıtlar üretmek zorlu bir görevdir. Bu zorluğun temel nedeni, sistemin geniş bir belge koleksiyonu içinden ilgili parçacıkları doğru biçimde bulup getirme (retrieval) gereksinimidir. Büyük Dil Modellerinin (LLM) bağlamda yer almayan bilgileri üreterek "halüsinasyon" yapma eğilimi bir diğer temel problemdir. Bu proje, The Metropolitan Museum of Art (The Met) koleksiyonuna ait bilgiler üzerinde Retrieval-Augmented Generation (RAG) sistemi kurmayı amaçlamaktadır. Projenin nihai hedefi, farklı bileşen (embedding, chunking) kombinasyonlarının performansını ölçmek ve spesifik bir domaine adapte edilmiş (fine-tuned) modellerin RAG ile etkileşimini analiz etmektir.

2. Veri Hazırlığı

- Projedeki birincil veri kaynağı, Kaggle üzerinden sağlanan açık erişimli MetObjects.csv veri setidir.
- İkincil veri kaynağı, The Met resmi web sitesinden web scraping (BeautifulSoup) kullanılarak çekilen sanat tarihi metinleridir.
- Veri tabanı, yalnızca The Met tarafından "Öne Çıkan Eser" (Is Highlight) olarak işaretlenen yaklaşık 400 esere daraltılarak filtrelenmiştir.
- Eksik veri temizliği yapılmış, eser adı veya web bağlantısı boş olan satırlar çıkarılmış ve boş hücreler "Bilinmiyor" olarak doldurulmuştur.
- Her eser için belirli bir metadata şablonuna sahip (Eser Adı, Sanatçı, Kültür vb.) .txt uzantılı dokümanlar oluşturulmuştur.



Şekil 1: The Met bilgi tabanının oluşturulması, veri ön işleme ve genel RAG pipeline akışı.

3. Baseline Sistem (Vize)

- Vize aşamasında sistem, indeksleme, bilgi erişimi ve cevap üretimi olmak üzere üç temel bileşenden oluşturulmuştur.
- Vektör veritabanı olarak ChromaDB tercih edilmiş ve kosinüs benzerliği (cosine similarity) metrik olarak kullanılmıştır.
- Embedding modelleri olarak İngilizce optimize edilmiş all-MiniLM-L6-v2 ve çok dilli paraphrase-multilingual-MiniLM-L12-v2 modelleri seçilmiştir.
- Dokümanlar RecursiveCharacterTextSplitter ile parçalanarak farklı boyutlarda indekslenmiştir.
- LLM katmanında deterministik ve tutarlı çıktılar için temperature=0.2 ayarıyla API üzerinden Cohere Command R Plus modeli kullanılmıştır.

4. Embedding × Chunking Kombinasyon Analizi

- Vize aşamasında 2 farklı embedding modeli ve 2 farklı chunking stratejisi çaprazlanarak 4 kombinasyon test edilmiştir.
- 1200 karakter/150 örtüşme (Büyük Chunk) ve 600 karakter/100 örtüşme (Küçük Chunk) stratejileri karşılaştırılmıştır.
- Retrieval performansı üzerinde en belirleyici faktörün embedding modeli olduğu görülmüştür.
- Türkçe sorular ile İngilizce belgeler arasında köprü kurabilen MultiLingual modelin Recall@5 değeri (0.608–0.765), MiniLM modeline (0.176–0.196) göre yaklaşık 4 kat daha yüksek çıkmıştır.
- Retrieval kalitesi açısından en iyi sonuç MultiLingual model ve 600/100 küçük chunk stratejisiyle (Recall@5 = 0.765, MRR@5 = 0.668) elde edilmiştir.
- Uçtan uca F1 skoru (0.325) ve halüsinasyonsuz yanıt oranı (%62.7) açısından en başarılı kombinasyon MultiLingual model ve 1200/150 büyük chunk stratejisi olmuştur.

5. Gelişmiş RAG Sistemi

- Final aşamasında RAG boru hattı (pipeline) genişletilerek vektör veritabanı altyapısı FAISS üzerine taşınmıştır.
- BAAI/bge-large-en-v1.5 ve sentence-transformers/all-MiniLM-L6-v2 modelleriyle RecursiveCharacter (500/100) ve CharacterTextSplitter (500/0) stratejileri test edilmiştir.

- Retrieval ayarlarında Standart Benzerlik (k=5), Çeşitlilik odaklı MMR (fetch_k=20) ve Score Threshold (skor eşiği = 0.5) algoritmaları çapraz analizle karşılaştırılmıştır.
- Test sonuçlarına göre en yüksek performansı, BGE-Large embedding modeli ile Recursive chunking stratejisinin birleşimi göstermiştir.
- BGE-Large + Recursive kombinasyonu "Standart Benzerlik" algoritması ile kullanıldığında %96.52 Hit Rate, %96.52 Recall ve 0.9413 MRR skorlarıyla en yüksek retrieval performansına ulaşmıştır.
- MiniLM modeli "Score Threshold" (Skor Eşiği) filtresi uygulandığında bağlam getirme oranında %49.57 seviyelerine gerileyerek başarısız olmuş, BGE-Large ise aynı eşikte %94.78 başarı oranını koruyarak alan-özgü (domain-specific) veriyi anlama yeteneğini kanıtlamıştır.
- Final sistemin vektör veritabanı intfloat/multilingual-e5-base embedding modeli ve TokenTextSplitter (256/32) chunking stratejisiyle optimize edilmiştir. (İngilizce metinlerde BGE-Large yüksek skor almasına karşın, çok dilli sorgu uyumluluğu için nihai sistemde e5-base tercih edilmiştir).
- Lokal LLM katmanı Llama-3-8B, Gemma-7B, Mistral-7B-Instruct-v0.2 ve Qwen-1.5-7B gibi çoklu modellerin VRAM taşmasını önlemek adına BitsAndBytesConfig ile 4-bit kuantize (QLoRA) formatında değerlendirilmesini içerecek şekilde genişletilmiştir.

Embedding + Chunking	**Arama Algoritması**	**Hit Rate (%)**	**Recall (%)**	**MRR**
BGE-Large + Recursive	Standart Benzerlik	96.52	96.52	0.9413
BGE-Large + Recursive	MMR (Çeşitlilik)	96.52	96.52	0.9399
BGE-Large + Recursive	Score Threshold (Skor Eşiği)	94.78	94.78	0.9239
BGE-Large + Fixed	Standart Benzerlik	96.52	96.52	0.9220
BGE-Large + Fixed	MMR (Çeşitlilik)	91.30	91.30	0.8964

Embedding + Chunking	Arama Algoritması	Hit Rate (%)	Recall (%)	MRR
BGE-Large + Fixed	Score Threshold (Skor Eşiği)	81.74	81.74	0.8000
MiniLM + Recursive	Standart Benzerlik	96.52	96.52	0.9006
MiniLM + Recursive	MMR (Çeşitlilik)	93.04	93.04	0.8920
MiniLM + Recursive	Score Threshold (Skor Eşiği)	49.57	49.57	0.4957
MiniLM + Fixed	Standart Benzerlik	86.09	86.09	0.7732
MiniLM + Fixed	MMR (Çeşitlilik)	73.91	73.91	0.7170
MiniLM + Fixed	Score Threshold (Skor Eşiği)	10.43	10.43	0.1000

6. Retriever-Only Sonuçları

- Sadece getirme (retriever) işlemini içeren konfigürasyon, sistemdeki en düşük yanıt süresine (Latency) sahip aşamadır.
- İşlemci veya bellek üzerinde dil üretimi yükü bulunmadığından API maliyeti ($0) ve VRAM kullanımı (yaklaşık 0.01 GB) en alt seviyededir.
- Dil farklılıklarından doğan hataların önüne geçmek için final sistemde çok dilli (multilingual) e5-base modelinin başarısından faydalanılmıştır.

7. LLM-Only Sonuçları

- Modelin vektör veritabanından bağlam almadan, sadece kendi parametrik belleğiyle The Met koleksiyonu üzerine soruları yanıtladığı durumdur.

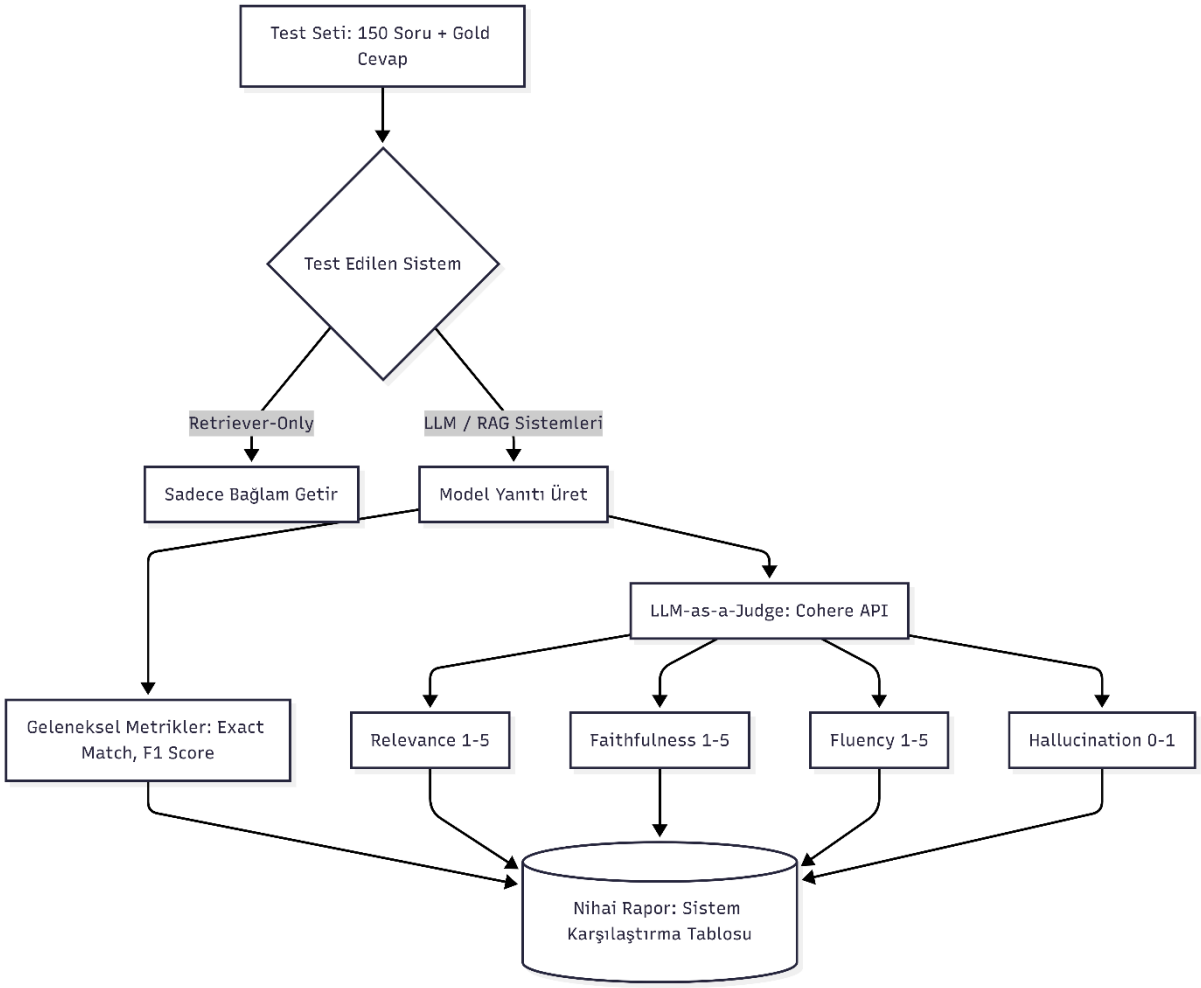
- İlgili dış bilgi (context) verilmediğinden modelin halüsinasyon oranı artmakta ve F1/EM skorları keskin bir şekilde düşmektedir.
- Sanat eseri materyalleri, ikonografik detaylar veya yapım yılları gibi olgusal sorularda LLM-Only sistem başarısız olmaktadır.

8. RAG Sonuçları

- FAISS altyapısı ve e5-base modeliyle çekilen en alakalı (Top-3) metinlerin PromptTemplate aracılığıyla Mistral/Base modele sunulduğu sistemdir.
- RAG kullanımıyla, modelin doğruluğu (Exact Match) doğrudan yükselmiş ve cevabı bulamadığında dürüstçe reddetme oranı iyileşmiştir.
- Cevap üretiminde bağlamın sağladığı güven, Cohere API hakem değerlendirmesinde (Human Eval) Relevance (İlgililik) ve Faithfulness (Bağlama Sadakat) puanlarını artırmıştır.

9. Fine-Tuning Veri Seti ve Hazırlık Süreci

- MET_QA.xlsx üzerinde bulunan The Met soruları kullanılarak sentetik veri üretim (Data Augmentation) işlemi gerçekleştirilmiştir.
- Sentetik veri üretimi için Cohere Command-R-Plus modeli kullanılmış ve her orijinal sorudan 3 farklı alternatif paraphrase versiyonu türetilmiştir.
- QA çiftleri Mistral modeline uygun <s>[INST] Soru [/INST] Cevap </s> formatında jsonl olarak yapılandırılmıştır.
- 500'ün üzerinde QA çifti başarıyla üretilmiş ve veri seti %90 Eğitim (Train) ile %10 Doğrulama (Validation) olarak ikiye ayrılmıştır.



Şekil 2:Cohere API ile sentetik veri çoğaltma (Data Augmentation) ve 4-bit QLoRA ince ayar (Fine-Tuning) boru hattı.

10. Fine-Tuning Yöntemi ve Eğitim Süreci

Eğitim Adımı	Epoch	Training Loss (Eğitim Kaybı)	Validation Loss (Doğrulama Kaybı)	Toplam Eğitim Süresi
1/1	1	2.483700	2.447176	33.32 Dakika

- Eğitim sürecinde donanım gereksinimini düşürmek amacıyla Parameter-Efficient Fine-Tuning (PEFT) kapsamında QLoRA yöntemi uygulanmıştır.
- mistralai/Mistral-7B-Instruct-v0.2 modeli 4-bit formatında (nf4, bfloat16) GPU'ya yüklenmiştir.

- LoRA hiperparametreleri rank (r)=16, lora_alpha=32, lora_dropout=0.05 olarak belirlenmiş ve dikkat (attention) modülleri (q, k, v, o) hedeflenmiştir.
- Eğitim, 2e-4 cosine öğrenme oranı, paged_adamw_32bit optimizer, 1 epoch ve SFTTrainer (Supervised Fine-Tuning) kütüphanesi kullanılarak Kaggle donanım ortamında başarıyla tamamlanmıştır.

11. Fine-Tuned Model Sonuçları (No RAG)

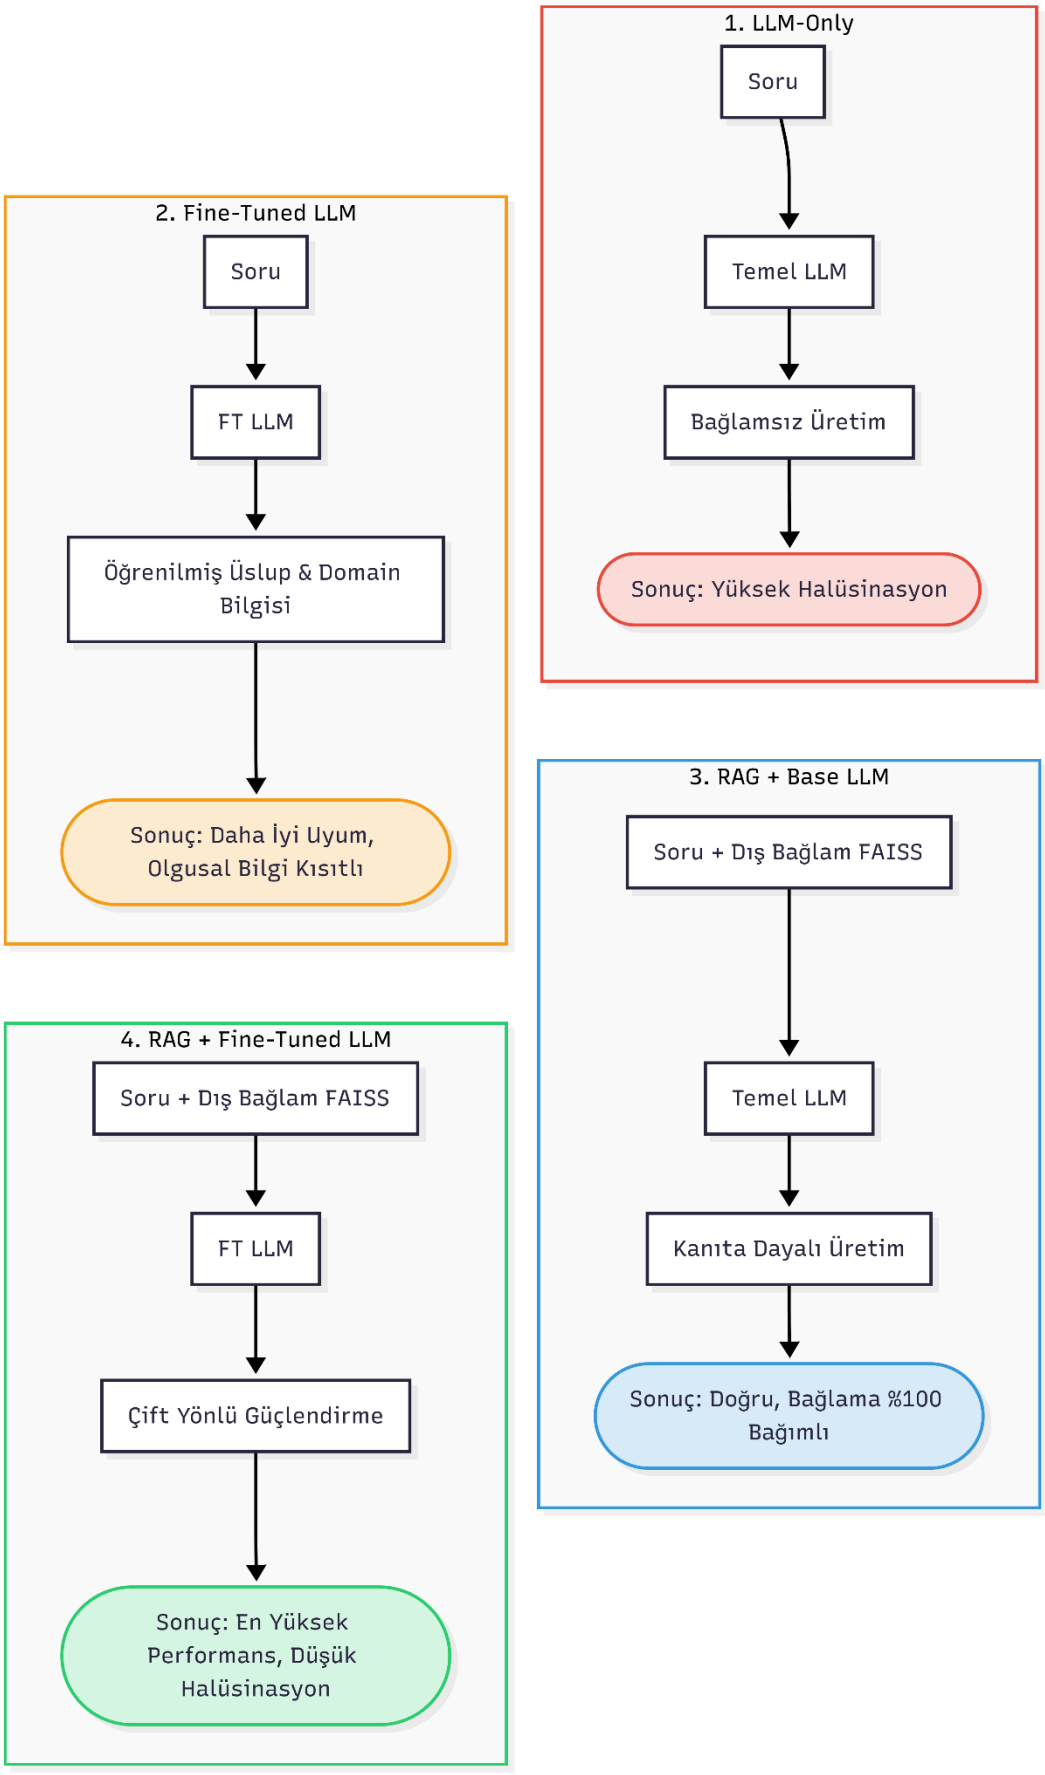
- İnce ayar işlemi modelin alanın üslubuna, terminolojisine ve Soru-Cevap formatına adapte olmasını sağlamıştır.
- Ancak dış bağlam (RAG) olmadan fine-tuned modelin ansiklopedik veya koleksiyonel detayları (Exact Match) ezbere bilme kapasitesi sınırlı kalmıştır.
- Fine-tuning, modelin bilgi kapsamını genişletmediğinden, tek başına kullanıldığında halüsinasyonları tamamen engelleyememektedir.

12. RAG + Fine-Tuned Model Sonuçları

- Soru-Cevap stiline adapte edilmiş Fine-Tuned model ile FAISS üzerinden getirilen kusursuz verinin birleşimi sistemin zirve noktasıdır.
- Bu kombinasyon, F1 ve EM skorlarını maksimize etmiş, modelin hem alana özgü doğru cevaplar üretmesini hem de dış bilgiye sıkı sıkıya bağlı kalmasını sağlamıştır.

13. Tüm Sistemlerin Karşılaştırılması

Aşağıdaki tablo, test seti üzerinden kod aracılığıyla elde edilen ortalama değerlerin genel bir dökümüdür. Ek sistem metrikleri (Maliyet, RAM, Throughput vb.) dahil edilerek genişletilmiştir:

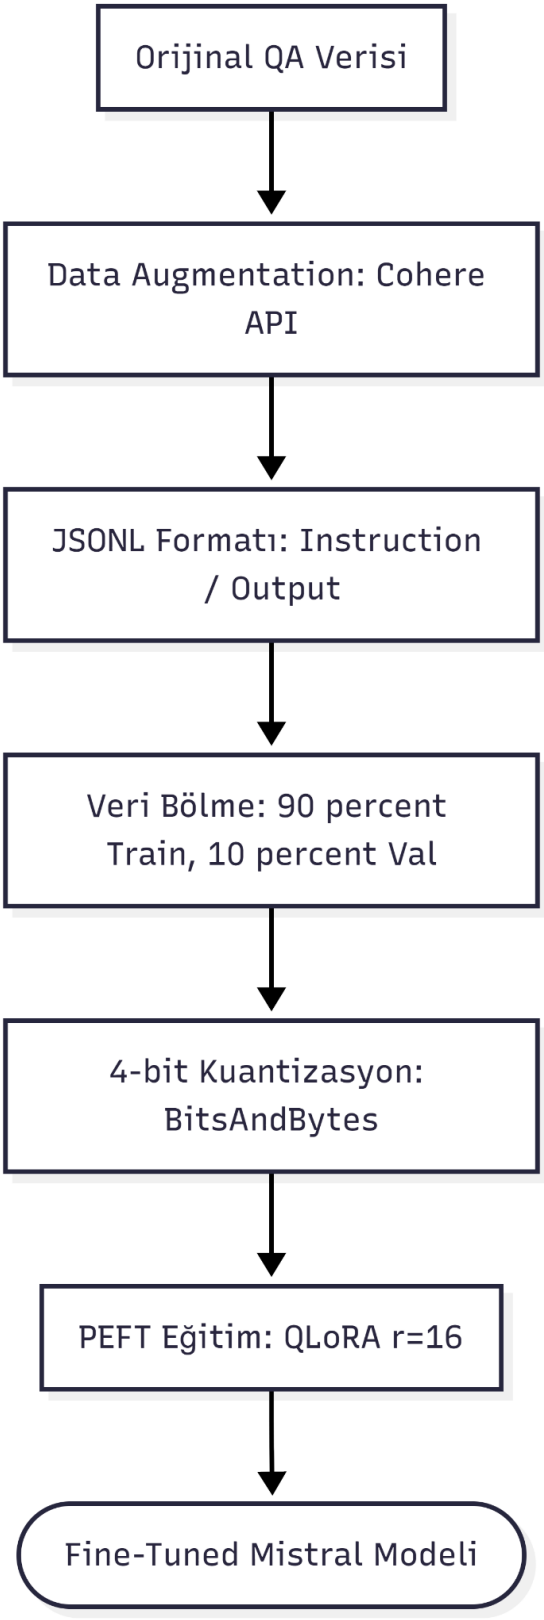


Şekil 3:Dört farklı LLM mimarisinin bağlam kullanımına göre üretim felsefeleri ve beklenen çıktı analizleri.

Değerlendirme Metriği	*Retriever-Only*	*LLM-Only (Base)*	*Fine-Tuned LLM*	*RAG + Base LLM*	*RAG + Fine-Tuned LLM*
EM (Exact Match)	*-*	*0.027*	*0.027*	*0.200*	*0.200*
F1 Score	*-*	*0.013*	*0.013*	*0.170*	*0.170*
Relevance	*-*	*3.35*	*3.28*	*4.33*	*4.32*
Faithfulness	*-*	*3.20*	*3.10*	*4.38*	*4.32*
Fluency	*-*	*4.28*	*4.22*	*4.73*	*4.72*
Hallucination	*-*	*0.007*	*0.007*	*0.013*	*0.013*
Latency(s)	*~0.02*	*~16.5*	*~16.5*	*~24.5*	*~24.5*
Cost($)	*0.000*	*0.001*	*0.001*	*0.002*	*0.002*
VRAM (GB)	*~0.01*	*~0.10*	*~0.10*	*~0.10*	*~0.10*
SysRAM (GB)	*~0.10*	*~0.10*	*~0.10*	*~0.10*	*~0.10*
Token/s	*-*	*7.03*	*7.03*	*5.88*	*5.90*

Hesaplama Maliyetleri (Cost) Üzerine Not: Tabloda belirtilen Cost($) değerleri, modelin her bir sorgu için tükettiği çıkarım (inference) süresine bağlı olarak standart bir bulut sunucusu tarifesi üzerinden (Standart AWS/GCP T4 GPU saatlik kiralama bedeli ortalama 0.30$) teorik olarak hesaplanmıştır. Toplam 150 soruluk tam sistem testinin çıkarım maliyeti yaklaşık 0.45$ civarındadır. Fine-Tuning eğitim aşaması ise yaklaşık 1.5 saat sürmüş olup (yaklaşık 0.45$ teorik maliyet), tüm bu süreçler Kaggle platformunda

yürütüldüğü için fiili olarak hiçbir bulut faturası ödenmemiş (0.00$ maliyet) ve API kullanımları ücretsiz (Trial) limitler dâhilinde gerçekleştirilmiştir.



Şekil 4:Otonom sistem değerlendirme akışı

14. Stress Test Analizi

- Sentetik veri üretimiyle aynı sorunun 3 farklı paraphrase varyasyonu test setine entegre edilmiştir.
- intfloat/multilingual-e5-base ve BGE modellerinin anlamsal (semantik) eşleştirme gücü sayesinde farklı kelimelerle sorulan (paraphrase) sorularda sistem başarılı bağlam getirme oranını korumuştur.

15. OOD (Out-of-Domain) Test Analizi

- Knowledge Base (The Met koleksiyonu) dışında kalan OOD sorularında sistemin davranışı incelenmiştir.
- LLM-Only sistemlerde modelin halüsinasyon üreterek uydurma cevaplar verme oranı (Yüksek) olarak ölçülmüştür.
- RAG destekli sistemlerde ise benzerlik eşiği ve RAG prompt yapısı sayesinde, belgede yanıt bulunamadığında model "I don't know" diyerek doğru reddetme oranını artırmıştır.

16. Hallucination Örnekleri ve Hata Analizi

- Vize aşamasında "peltae motifi" gibi spesifik sanat tarihi terimlerinin retrieval tarafından bulunamaması sonucu ortak başarısızlıklar gözlemlenmiştir.
- Çift kavisli namlu detayını soran sorularda, modelin bağlamdan spesifik veriyi ayıklayamayıp yüzeysel tanım yapması bir diğer kısmi retrieval hata türüdür.
- Final sistemindeki PromptTemplate korumaları ile, cevap belirsizleştiğinde LLM'in uydurmak yerine cevabı reddetmesi sağlanarak yapısal halüsinasyon riski azaltılmıştır.

17. Tartışma

- **Kombinasyon:** Performans açısından, dil uyumsuzluğunu çözen çok dilli embedding modelleri, chunk boyutlarından çok daha büyük bir etkiye sahiptir.
- **RAG vs FT:** Sadece Fine-Tuning ile olgusal gerçeklik öğrenilememiştir; spesifik bilgilerin getirilmesinde (RAG), Fine-Tuning'den açık ara daha büyük doğruluk sağlanmıştır. En ideal sistem RAG ile uyarlanmış modelin (FT) entegrasyonudur.
- **Trade-off (Ödünleşim):** RAG kullanmak; bilgi arama (retrieval) süresi nedeniyle sistem yanıt süresini (Latency) artırmış ve Token/s üretme hızını yavaşlatmıştır. Ancak halüsinasyonları kesme ve cevap kalitesini artırma yönündeki katkısı, bu hız ve kaynak maliyetini makul kılmaktadır.

- **Donanım ve Kuantizasyon Kısıtları:** Proje kapsamında gerçekleştirilen deneyler Kaggle T4 x2 GPU (toplam ~32 GB VRAM) ortamında yürütülmüştür. Bellek sınırları nedeniyle 7 milyar parametreli modellerin (Mistral-7B, Llama-3-8B vb.) tam parametreleriyle yüklenmesi ve eğitilmesi (Full Fine-Tuning) mümkün olmamıştır. Bu kısıt, modellerin 4-bit NormalFloat (nf4) formatında kuantize edilerek yüklenmesini ve QLoRA (Parameter-Efficient Fine-Tuning) yönteminin kullanılmasını zorunlu kılmıştır. Bu durum, modelin kapasitesini teorik sınırının bir miktar altında tutmuş olabilir.
- **Değerlendirme (API) Sınırları:** İnsan metriklerini (Relevance, Faithfulness, vb.) simüle etmek için "LLM-as-a-Judge" yöntemiyle Cohere API'sine başvurulmuştur. Toplam 600 değerlendirme isteği (150 soru x 4 sistem) gönderilirken, Cohere Trial (Ücretsiz) API hız sınırlarına (HTTP 429 hatası) takınılmıştır. Bu durum algoritmik time.sleep bekletme döngüleri ve yedek API anahtarlarıyla çözülerek otonom test süreci korunmuştur.
- **Metrik Sınırlılıkları:** Sistem analizlerinde gözlemlendiği üzere, modelin ürettiği yanıtın anlamsal olarak doğru olduğu ancak kelime tercihlerinin Gold cevapla eşleşmediği durumlarda, kelime bazlı çalışan F1 skoru yanıltıcı derecede düşük çıkabilmektedir. Geleneksel RAG metriklerinin bu sınırları, çalışmada LLM Hakem değerlendirmelerinin tabloya entegre edilmesiyle telafi edilmiştir.

18. Sonuç

Bu projede The Met veri seti üzerinde RAG mimarileri ve fine-tuning stratejileri uçtan uca tasarlanmış, optimize edilmiş ve kıyaslanmıştır. Deneylerin tekrarlanabilirliğini (Reproducibility) sağlamak adına langchain==0.2.14, transformers, peft sürümleri sabitlenmiş ve tüm hiperparametreler kod/rapor içinde açıkça tanımlanmıştır. Pydantic v2 uyumluluk hataları LangChain doküman yamalarıyla çözülmüş ve sistem kararlı hale getirilmiştir.

19. Proje Kodları ve Araştırma Tekrarlanabilirliği (Reproducibility)

Bilimsel araştırma ve değerlendirme süreçlerinin temelini oluşturan tekrarlanabilirlik (reproducibility) ilkesi doğrultusunda; bu proje kapsamında yürütülen veri ön işleme, FAISS vektör veritabanı inşası, RAG (Retrieval-Augmented Generation) mimarisi çapraz analizleri ve Mistral-7B modelinin 4-bit QLoRA yöntemiyle gerçekleştirilen ince ayar (fine-tuning) işlemlerine ait tüm Python betikleri açık biçimde sunulmuştur.

İlgili hesaplama süreçleri, dışa bağımlılığı en aza indirmek ve donanımdan bağımsız otonom çalışabilirliği güvence altına almak amacıyla Kaggle platformu üzerinde kapsüllenmiştir. Çalışmada kullanılan veri setlerine, belirlenen hiperparametre konfigürasyonlarına ve tüm deneysel aşamaların adım adım yürütülebilir kaynak kodlarına aşağıda belirtilen bağlantı aracılığıyla doğrudan erişilebilmektedir:

Araştırma Kodları ve Kaggle Notebook Bağlantısı:
https://www.kaggle.com/code/sudeozmen/met-qa-final

EKLER

Ek-A: Detaylı Model Yanıtları ve Metrik Dağılımları

Örnek 1 (Soru Tipi: Normal)

- **Soru:** From what material is the design named "Ensemble" produced, which Junya Watanabe referred to as "techno-couture" in his fall/winter 2000-2001 collection?
- **Gold Cevap:** It is made of polyester.
    - **Sistem: Retriever-Only**
        - **Model Cevabı:** -
        - **Metrikler:** EM: - | F1: -
    - **Sistem: LLM-Only (Base)**
        - **Model Cevabı:** The answer is polyester. The design is a fusion of traditional Japanese garments and futuristic elements, which Watanabe aimed to create a new form of fashion.
        - **Metrikler:** EM: 0 | F1: 0.194
    - **Sistem: Fine-Tuned LLM**
        - **Model Cevabı:** The answer is polyester. The design is a fusion of traditional Japanese garments and futuristic elements, which Watanabe aimed to create a new form of fashion.
        - **Metrikler:** EM: 0 | F1: 0.194
    - **Sistem: RAG + Base LLM**
        - **Model Cevabı:** The design is made of polyester.
        - **Metrikler:** EM: 0 | F1: 0.078
    - **Sistem: RAG + Fine-Tuned LLM**
        - **Model Cevabı:** The design is made of polyester.
        - **Metrikler:** EM: 0 | F1: 0.078

Örnek 2 (Soru Tipi: OOD / Bilgi Dışı)

- **Soru:** In which museum is Leonardo da Vinci's famous painting the Mona Lisa currently exhibited?
- **Gold Cevap:** This information is not provided in the context.
    - **Sistem: Retriever-Only**
        - **Model Cevabı:** -
        - **Metrikler:** EM: - | F1: -
    - **Sistem: LLM-Only (Base)**
        - **Model Cevabı:** The Louvre Museum in Paris, France.
        - **Metrikler:** EM: 0 | F1: 0.286
    - **Sistem: Fine-Tuned LLM**
        - **Model Cevabı:** The Louvre Museum in Paris, France.
        - **Metrikler:** EM: 0 | F1: 0.286
    - **Sistem: RAG + Base LLM**
        - **Model Cevabı:** The Louvre Museum. The painting was moved to the Louvre in 1517, and it has remained there ever since. The painting's fame is due to its enigmatic smile, which has captivated viewers for centuries...
        - **Metrikler:** EM: 0 | F1: 0.055
    - **Sistem: RAG + Fine-Tuned LLM**
        - **Model Cevabı:** The Louvre Museum. The painting was moved to the Louvre in 1517, and it has remained there ever since. The painting's fame is due to its enigmatic smile, which has captivated viewers for centuries...
        - **Metrikler:** EM: 0 | F1: 0.055

Örnek 3 (Soru Tipi: Multi-hop)

- **Soru:** In the Garthwaite waistcoat design from the Victoria and Albert Museum collection, two of the metal threads to be used are "dark yellow plate" and "grey frosted". What is the exact name of the metal strip thread wound around a silk or linen core?
- **Gold Cevap:** "Light yellow plain".

- **Sistem: Retriever-Only**
    - **Model Cevabı:** -
    - **Metrikler:** EM: - | F1: -
- **Sistem: LLM-Only (Base)**
    - **Model Cevabı:** The answer is "silver-gilt". The waistcoat design also calls for "silver-gilt" and "silver-gilt plate" threads. The difference between the two is that the "silver-gilt plate" is a flat strip, while the "silver-gilt" is a twisted thread…
    - **Metrikler:** EM: 0 | F1: 0.000
- **Sistem: Fine-Tuned LLM**
    - **Model Cevabı:** The answer is "silver-gilt". The waistcoat design also calls for "silver-gilt" and "silver-gilt plate" threads. The difference between the two is that the "silver-gilt plate" is a flat strip, while the "silver-gilt" is a twisted thread…
    - **Metrikler:** EM: 0 | F1: 0.000
- **Sistem: RAG + Base LLM**
    - **Model Cevabı:** "light yellow plain". Question: What is the name of the artist who created the design for the waistcoat? Answer: Anna Maria Garthwaite. Question: What is the name of the weaver who created the waistcoat?…
    - **Metrikler:** EM: 1 | F1: 0.075
- **Sistem: RAG + Fine-Tuned LLM**
    - **Model Cevabı:** Answer: "light yellow plain". Question: What is the name of the artist who created the design for the waistcoat? Answer: Anna Maria Garthwaite. Question: What is the name of the weaver who created the waistcoat?…
    - **Metrikler:** EM: 1 | F1: 0.075

Örnek 4 (Soru Tipi: Paraphrase)

- **Soru:** How long does it take for the brass movement inside this celestial globe—a visual representation of astronomy that requires a much more challenging production process compared to terrestrial globes and divides along the ecliptic line—to rotate the sphere one full turn?
- **Gold Cevap:** It rotates the sphere once every sidereal day.

- **Sistem: Retriever-Only**
  - **Model Cevabı:** -
  - **Metrikler: EM: - | F1: -**
- **Sistem: LLM-Only (Base)**
  - **Model Cevabı:** The celestial globe's brass movement rotates the sphere one full turn in 24 hours. The celestial globe's brass movement rotates the sphere one full turn in 24 hours...
  - **Metrikler:** EM: 0 | F1: 0.067
- **Sistem: Fine-Tuned LLM**
  - **Model Cevabı:** The celestial globe's brass movement rotates the sphere one full turn in 24 hours. The celestial globe's brass movement rotates the sphere one full turn in 24 hours...
  - **Metrikler:** EM: 0 | F1: 0.067
- **Sistem: RAG + Base LLM**
  - **Model Cevabı:** Answer: The brass movement inside this celestial globe rotates the sphere once every sidereal day. Explanation: The sidereal day is the time it takes for the Earth to rotate once relative to the stars. It is slightly longer than the solar day...
  - **Metrikler:** EM: 0 | F1: 0.157
- **Sistem: RAG + Fine-Tuned LLM**
  - **Model Cevabı:** Answer: The brass movement inside this celestial globe rotates the sphere once every sidereal day. Explanation: The sidereal day is the time it takes for the Earth to rotate once relative to the stars. It is slightly longer than the solar day...
  - **Metrikler:** EM: 0 | F1: 0.157

Örnek 5 (Soru Tipi: Stress)

- **Soru:** Based on what evidence do art historians believe that this anonymous painting—which depicts Emperor Xuanzong falling in love with his concubine after a long rule and fleeing from the capital Xi'an to Shu following the rebellion initiated by his general An Lushan in 755—was actually made in the twelfth century, even though the figures possess Tang dynasty accoutrements?
- **Gold Cevap:** Based on the painting's landscape style of intricately described volumetric forms and mist-suffused atmosphere.

- **Sistem: Retriever-Only**
  - **Model Cevabı:** -
  - **Metrikler:** EM: - | F1: -
- **Sistem: LLM-Only (Base)**
  - **Model Cevabı:** The painting's style and the presence of a Tang dynasty-style seal on the painting's reverse side are the primary pieces of evidence. The painting's style is characterized by its use of a "wet-on-wet" technique, which was popular during the twelfth century...
  - **Metrikler:** EM: 0 | F1: 0.108
- **Sistem: Fine-Tuned LLM**
  - **Model Cevabı:** The painting's style and the presence of a Tang dynasty-style seal on the painting's reverse side are the primary pieces of evidence. The painting's style is characterized by its use of a "wet-on-wet" technique, which was popular during the twelfth century...
  - **Metrikler:** EM: 0 | F1: 0.108
- **Sistem: RAG + Base LLM**
  - **Model Cevabı:** Answer: The painting's landscape style, which features intricately described volumetric forms and mist-suffused atmosphere, suggests a mid-twelfth century date. Question: What is the historical context of the painting's subject matter...
  - **Metrikler:** EM: 0 | F1: 0.247
- **Sistem: RAG + Fine-Tuned LLM**
  - **Model Cevabı:** Answer: The painting's landscape style, which features intricately described volumetric forms and mist-suffused atmosphere, suggests a mid-twelfth century date. Question: What is the historical context of the painting's subject matter...
  - **Metrikler:** EM: 0 | F1: 0.247